PLANO DE ENSINO E APRENDIZAGEM

CURSO	PROFESSOR	UNIDADE CURRICULAR	PERÍODO LETIVO
Análise e Desenvolvimento de Sistemas e Sistemas de Informação	Alex Rogaleski Marques	Big Data e Ciências de Dados	2026.2

TURNO	ANO MÓDULO	CARGA HORÁRIA DAS ATIVIDADES ACADÊMICAS (Horas)					CARGA HORÁRIA TOTAL (Horas)
		Teórica (Presencial)	Prática (Presencial)	Trabalho Efetivo Discente (TED) (Supervisionado)	Extensão (TED) (Presencial)	EaD	
Noturno	2° ano de ADS e 4º ano de SI / módulo azul	30h	30h	10h	10h	-	80h

EMENTA

Conceitos fundamentais de Big Data e Ciência de Dados. Arquiteturas e tecnologias de Big Data. Armazenamento e processamento de grandes volumes de dados: Hadoop, Spark e bancos de dados NoSQL. Coleta, limpeza e preparação de dados. Análise exploratória de dados e visualização. Modelagem e análise de dados utilizando técnicas de machine learning. Ferramentas e linguagens de programação para ciência de dados: Python, R e SQL. Implementação de pipelines de dados e automação de processos analíticos. Ética e privacidade em ciência de dados.

COMPETÊNCIAS E HABILIDADES

- Compreender os conceitos e a importância do Big Data e da Ciência de Dados no contexto atual.
- Utilizar arquiteturas e tecnologias de Big Data para armazenamento e processamento de grandes volumes de dados.
- Coletar, limpar e preparar dados para análise.
- Realizar análise exploratória de dados e criar visualizações informativas.
- Aplicar técnicas de machine learning para modelagem e análise de dados.
- Utilizar ferramentas e linguagens de programação como Python, R e SQL para desenvolvimento de soluções em ciência de dados.
- Implementar e gerenciar pipelines de dados para automação de processos analíticos.
- Aplicar princípios éticos e de privacidade na manipulação e análise de dados.
- Desenvolver soluções de Big Data que sejam escaláveis e eficientes para diferentes domínios de aplicação.

UNIDADES TEMÁTICAS

1. **Fundamentos de Big Data e Ciência de Dados**
    a. O que é Big Data? (Os 5 Vs: Volume, Velocidade, Variedade, Veracidade e Valor)
    b. O que é Ciência de Dados? O ciclo de vida de um projeto de Ciência de Dados.
    c. Interconexões e diferenças: Business Intelligence (BI), Análise de Dados, Big Data e Ciência de Dados.
    d. O papel do Cientista de Dados e do Engenheiro de Dados: habilidades, responsabilidades e mercado de trabalho.
2. **Arquiteturas e Ecossistema de Big Data**
    a. Arquiteturas de referência para processamento de dados (Lambda e Kappa).
    b. O Ecossistema Hadoop: HDFS (Armazenamento Distribuído), YARN (Gerenciamento de Recursos) e MapReduce (Modelo de Processamento).
    c. Introdução ao Apache Spark: O sucessor do MapReduce e seu poder de processamento em memória.
    d. Visão geral de outras ferramentas do ecossistema (Hive, Pig, Zookeeper).
3. **Armazenamento de Dados em Larga Escala (NoSQL)**
    a. Limitações dos bancos de dados relacionais (SQL) no contexto de Big Data.
    b. Introdução e motivação para os bancos de dados NoSQL.
    c. Categorias de bancos NoSQL e seus casos de uso:
        i. Documento (ex: MongoDB)
        ii. Chave-Valor (ex: Redis)
        iii. Colunar (ex: Cassandra)
        iv. Grafo (ex: Neo4j)
    d. Critérios para a escolha do banco de dados NoSQL adequado.
4. **Ferramentas e Linguagens para Análise de Dados**
    a. Python como linguagem padrão para Ciência de Dados: Ambiente e ferramentas (Jupyter Notebooks, Google Colab).
    b. Biblioteca NumPy: Computação numérica e arrays multidimensionais.
    c. Biblioteca Pandas: Manipulação e análise de dados através de DataFrames.
    d. O papel contínuo do SQL em ambientes de Big Data.
    e. Introdução ao R e RStudio como alternativa para análise estatística.
5. **O Processo de Ciência de Dados na Prática**
    a. Coleta de Dados: Fontes (APIs, Web Scraping, Bancos de Dados) e métodos.
    b. Limpeza e Pré-processamento de Dados (Data Wrangling): Tratamento de valores ausentes, outliers e inconsistências.
    c. Análise Exploratória de Dados (EDA): Estatística descritiva e identificação de padrões.
    d. Visualização de Dados: Princípios e ferramentas (Matplotlib, Seaborn) para geração de insights.
6. **Modelagem Preditiva com Machine Learning**
    a. Conceitos fundamentais: Aprendizagem Supervisionada, Não Supervisionada e por Reforço.
    b. Algoritmos de Regressão: Prevendo valores contínuos (ex: Regressão Linear).
    c. Algoritmos de Classificação: Prevendo categorias (ex: Árvores de Decisão, K-NN).
    d. Algoritmos de Clusterização: Agrupando dados similares (ex: K-Means).
    e. Avaliação de Modelos: Métricas de performance e validação.
7. **Engenharia de Dados e Ética**
    a. Implementação de Pipelines de Dados: O que são e por que são importantes.
    b. Ferramentas para orquestração e automação de processos analíticos (ex: Apache Airflow).
    c. Ética e Privacidade em Ciência de Dados: Viés algorítmico, transparência e explicabilidade.

d. A Lei Geral de Proteção de Dados (LGPD) e seu impacto em projetos de dados.

METODOLOGIA

A unidade curricular de **Big Data e Ciência de Dados** busca capacitar os estudantes a compreender, projetar e implementar soluções analíticas escaláveis, capacitando-os a transformar grandes volumes de dados brutos e não estruturados em conhecimento estratégico e tomada de decisão. Para alcançar esse objetivo, será adotada uma abordagem didática progressiva e prática que articula os fundamentos conceituais de ecossistemas distribuídos, o pré-processamento de dados e a modelagem preditiva com a aplicação concreta em problemas reais da sociedade e do mercado.

A metodologia será fundamentada nas seguintes abordagens pedagógicas:

- **Aulas Expositivas Dialogadas:** As aulas teóricas serão utilizadas para apresentar os fundamentos de Big Data, os modelos de arquiteturas de referência (Lambda e Kappa) e o funcionamento interno de ecossistemas de processamento em larga escala (Hadoop, MapReduce, Apache Spark) e armazenamento NoSQL. A exposição incentivará a análise crítica sobre a escolha da tecnologia adequada para diferentes cenários de Volume, Velocidade e Variedade de dados.
- **Estudo Dirigido e Análise de Casos de Negócio:** Atividades orientadas de análise de problemas do mundo real para contextualizar a aplicação de Ciência de Dados em áreas como inteligência competitiva, saúde, finanças e e-commerce. Os estudantes exercitarão a formulação de perguntas de negócio, a definição de métricas de sucesso e a identificação das fontes de dados necessárias antes da fase de implementação técnica.
- **Laboratório de Programação e Análise Prática de Dados:** Grande parte das aulas será desenvolvida em laboratório de informática utilizando ambientes interativos (Jupyter Notebooks e Google Colab). Os discentes praticarão a carga, a manipulação, a limpeza (Data Wrangling), a análise exploratória (EDA) e a criação de visualizações de dados com bibliotecas padrão da indústria (Pandas, NumPy, Matplotlib, Seaborn) e o treinamento de modelos de Machine Learning (Scikit-learn).
- **Aprendizagem Baseada em Desafios (Gamificação):** Resolução de listas de exercícios práticos em plataformas de julgamento online (como o BeeCrowd), com foco na consolidação do raciocínio lógico-matemático, manipulação de estruturas de dados e tratamento de cenários analíticos com complexidade progressiva.
- **Cultura Maker e Projetos de Extensão Universitária (PBL Extensionista):** Realização de Trabalhos Efetivos Discentes (TEDs) estruturados de forma integradora. Além das etapas de desenvolvimento técnico de modelos preditivos, a disciplina incorporará a dimensão extensionista, na qual os alunos atuarão diretamente junto a organizações parceiras (empresas públicas, privadas ou entidades do terceiro setor). Os estudantes realizarão o diagnóstico de necessidades de dados locais, aplicarão princípios de governança, ética e conformidade com a Lei Geral de Proteção de Dados (LGPD) e entregarão uma solução analítica funcional (Data Storytelling, relatórios executivos ou dashboards) com impacto real para a comunidade.
- **Avaliações Diversificadas e Integradas:** O processo avaliativo será contínuo e contemplo instrumentos variados, incluindo avaliações escritas e práticas individuais em laboratório, listas de exercícios extraclasse, a validação técnica de notebooks com código-fonte e a defesa oral dos resultados dos projetos extensionistas frente ao professor e à turma. Serão avaliados a exatidão dos algoritmos, o rigor na avaliação das métricas de performance dos modelos, a clareza visual na comunicação dos dados e a postura ética na manipulação das informações.

TRABALHO EFETIVO DISCENTE

Abaixo estão descritos os trabalhos que compõem a carga horária de trabalhos efetivos discentes, totalizando 20 horas semestrais (sendo 10 horas de TED Acadêmico e 10 horas de TED de Extensão Universitária).

TED 01: Etapa 1 - Prospecção, Diagnóstico e Coleta de Dados no Parceiro (TED Extensão)

- **Tema:** Mapeamento de Problemas de Dados, Levantamento de Requisitos e Carga Inicial do Dataset.
- **Objetivo da Atividade:** Identificar uma necessidade real de gestão ou análise de dados de um parceiro da comunidade e transformar essa demanda em um projeto de Ciência de Dados viável, realizando o diagnóstico e a carga inicial do conjunto de dados brutos que será trabalhado ao longo de todo o semestre.
- **Observação (Projeto Integrador):** Esta atividade é desenvolvida de forma integrada com a disciplina de **Programação para Web**. O cliente/parceiro da comunidade, o domínio de negócio e a equipe deverão ser os mesmos em ambas as disciplinas. A base de dados brutos trabalhada nesta disciplina poderá ser originada do próprio banco de dados da aplicação web em desenvolvimento, fornecida diretamente pelo parceiro ou gerada/simulada com base nas regras de negócio da aplicação.
- **Descrição das Tarefas:** Nesta primeira etapa, cada equipe deverá selecionar um cliente ou parceiro da comunidade externa (empresa, ONG, associação, órgão público, microempreendedor ou profissional liberal). Após reuniões e entrevistas de diagnóstico com os gestores, deverá ser elaborado o planejamento inicial do projeto contendo a definição do problema de negócio, perguntas a serem respondidas, requisitos de dados e arquitetura analítica proposta. A equipe também deverá obter e realizar a carga inicial da base de dados brutos cedida pelo parceiro.
- **Entrega:** Primeira versão do **Documento Técnico do Projeto**, elaborada em PDF conforme as normas da ABNT, contendo obrigatoriamente:
    1. Identificação da equipe;
    2. Apresentação da instituição ou cliente atendido;
    3. Descrição do problema de negócio/gestão identificado;
    4. Justificativa social e valor gerado pela análise de dados;
    5. Levantamento de requisitos funcionais e não funcionais do projeto analítico;
    6. Definição das perguntas de negócio/pesquisa a serem respondidas;
    7. Arquitetura de dados proposta e tecnologias que serão utilizadas (Python, Pandas, NoSQL, Spark, etc.);
    8. Cronograma simplificado de execução;
    9. Termo de Parceria e Autorização do Tratamento de Dados assinado pelo parceiro;
    10. Referências bibliográficas.
- Além do documento em PDF, deverão ser entregues:
    - Link do repositório Git criado para o projeto;
    - Notebook interativo (.ipynb) contendo a **inspeção técnica inicial dos dados** (shape, tipos de colunas, contagem de nulos e identificação primária de falhas).
- *Esta entrega corresponde à Versão 1.0 do Documento Técnico do Projeto, que será atualizado e ampliado nas TEDs subsequentes, preservando o conteúdo das etapas anteriores e*

incorporando as novas seções desenvolvidas ao longo do semestre.

- **Forma de Realização:** Em grupo.
- **Método de Avaliação:** Avaliação do Documento Técnico v1.0 e do Notebook de Inspeção Inicial. A nota considerará a validação e autorização do parceiro (30%), a clareza do problema de negócio e do documento ABNT (40%) e a inspeção técnica inicial da base no notebook (30%).
- **Data de Entrega:** 12/09/2026
- **Valor:** 1,5 pontos.

TED 02: Etapa 2 - Limpeza, Saneamento e Análise Exploratória (TED Acadêmico)

- **Tema:** Data Wrangling, Tratamento de Inconsistências e Análise Exploratória de Dados (EDA).
- **Objetivo da Atividade:** Dando continuidade ao TED 01 e utilizando a mesma base do parceiro, realizar o tratamento completo das imperfeições dos dados e extrair os primeiros insights estatísticos e gráficos sobre o problema da organização.
- **Descrição das Tarefas:**
  1. Tratar valores ausentes, remover duplicidades, identificar outliers e realizar a conversão de tipos de variáveis no dataset do parceiro.
  2. Calcular estatísticas descritivas (média, mediana, desvio padrão) das variáveis relevantes para o problema de negócio.
  3. Criar visualizações gráficas preliminares (histogramas, boxplots, gráficos de dispersão com Matplotlib/Seaborn) que ajudem a responder às perguntas formuladas na Etapa 1.
- **Entrega:** Segunda versão do **Documento Técnico do Projeto (Versão 2.0 - PDF ABNT)**, atualizada e ampliada, mantendo todo o conteúdo do TED 01 e incorporando obrigatoriamente:
  1. Relatório detalhado das técnicas de limpeza e saneamento aplicadas (Data Wrangling);
  2. Seção de Análise Exploratória de Dados (EDA) com gráficos formatados e suas respectivas interpretações analíticas direcionadas ao parceiro;
  3. Atualização do Histórico de Versões do documento.
- Além do PDF, o **repositório Git** deverá ser atualizado contendo:
  - Notebook interativo (.ipynb) documentado, executável e comentado com todo o pipeline de limpeza e geração dos gráficos exploratórios;
  - Base de dados tratada/saneada gerada ao final do processo.
- **Forma de Realização:** Em grupo (continuidade do projeto).
- **Método de Avaliação:** Avaliação do Documento Técnico v2.0 e do Notebook de Saneamento/EDA no Git. A nota considerará a correção das técnicas de limpeza de dados (50%) e a qualidade dos insights/gráficos gerados para o parceiro (50%).
- **Data de Entrega:** 22/09/2026
- **Valor:** 1,5 pontos.

TED 03: Etapa 3 - Modelagem Preditiva e Machine Learning (TED Acadêmico)

- **Tema:** Aprendizado de Máquina (Regressão, Classificação ou Clusterização) e Avaliação de Modelos.
- **Objetivo da Atividade:** Utilizar a base limpa do parceiro (gerada no TED 02) para construir e

validar um modelo de Machine Learning que resolva ou preveja o problema de negócio mapeado na organização.

- **Descrição das Tarefas:**
  1. Definir a tarefa de Machine Learning adequada para o problema da empresa (ex: prever vendas, classificar inadimplência, segmentar clientes/usuários).
  2. Dividir os dados em treino e teste e treinar algoritmos utilizando a biblioteca Scikit-learn.
  3. Avaliar o desempenho do modelo através das métricas apropriadas (Acurácia, Precisão, Recall, F1-Score, Matriz de Confusão ou Silhueta) e ajustar hiperparâmetros para otimizar o resultado.
- **Entrega:** Terceira versão do **Documento Técnico do Projeto (Versão 3.0 - PDF ABNT)**, acumulando as versões anteriores e incluindo obrigatoriamente:
  1. Descrição da metodologia de Machine Learning escolhida e justificativa do algoritmo;
  2. Definição da estratégia de divisão de dados (treino/teste) e tratamento de variáveis (encoding, normalização);
  3. Apresentação e discussão detalhada das métricas de desempenho obtidas;
  4. Interpretação prática dos resultados do modelo aplicados ao problema do parceiro;
  5. Atualização do Histórico de Versões do documento.
- Além do PDF, o **repositório Git** deverá ser atualizado contendo:
  - Notebook interativo (.ipynb) com o código completo do treinamento, validação e salvamento do modelo de Machine Learning (ex: exportação do modelo treinado em formato .pkl ou .joblib);
  - Scripts ou rotinas reutilizáveis para inferência/predição de novos dados.
- **Forma de Realização:** Em grupo (continuidade do projeto).
- **Método de Avaliação:** Avaliação do Documento Técnico v3.0 e dos Scripts/Notebooks de ML no Git. A nota considerará o rigor metodológico do treino/teste (40%), a adequação do algoritmo escolhido (30%) e a interpretação das métricas no contexto da empresa (30%).
- **Data de Entrega:** 03/11/2026
- **Valor:** 1,5 pontos.

TED 04: Etapa 4 - Análise Ética/LGPD, Data Storytelling e Entrega da Solução Final (TED Extensão)

- **Tema:** Auditoria Ética/LGPD, Data Storytelling, Entrega da Solução e Apresentação Final.
- **Objetivo da Atividade:** Concluir o projeto analítico, realizar a auditoria ética/LGPD do modelo, validar a solução junto ao parceiro da comunidade e apresentar os resultados executivos alcançados.
- **Observação (Projeto Integrador):** A entrega final consolida o ecossistema completo do Projeto Integrador. A solução de inteligência de dados desenvolvida nesta disciplina (dashboards, modelos preditivos, rotinas de Machine Learning e relatórios de insights) integrará ou complementará a aplicação web desenvolvida e publicada na disciplina de **Programação para Web**, oferecendo uma entrega analítica e funcional completa para o parceiro.
- **Descrição das Tarefas:** Nesta etapa final, as equipes deverão finalizar o desenvolvimento do produto de dados (Dashboard, Pipeline de Dados automatizado, Relatório Executivo com Recomendações de Ação ou Notebook Operacional), devidamente validado junto ao parceiro.

A equipe deverá realizar a auditoria de viés algorítmico e de conformidade com a LGPD. Além da entrega técnica, as equipes deverão apresentar os resultados obtidos utilizando a técnica de *Data Storytelling* (narrativa visual voltada para público gestor), demonstrando o impacto da solução e as lições aprendidas.

- **Entrega:** O repositório Git deverá conter a versão final do projeto de dados, incluindo:
  1. Código-fonte completo e atualizado dos notebooks e scripts analíticos;
  2. Documentação técnica atualizada;
  3. Instruções de instalação, dependências e execução das rotinas de dados (README);
  4. Scripts de extração, tratamento, carga e geração de gráficos/modelos;
  5. Demais artefatos necessários para a execução ou visualização da solução (ex: links de dashboards interativos).
- Também deverão ser entregues:
  - Apresentação executiva em formato **Pitch com Data Storytelling** (slides com narrativa visual);
  - Vídeo curto (screencast) demonstrando a execução das rotinas de dados e a navegação nos gráficos/modelos gerados;
  - Comprovante/Declaração de Validação e Recebimento da Solução assinado pelo parceiro da comunidade.
- Também deverá ser entregue a **Versão Final do Documento Técnico do Projeto** (PDF - ABNT), consolidando todas as etapas desenvolvidas ao longo do semestre e preservando o conteúdo das versões anteriores. O documento deverá conter, além dos elementos das TEDs anteriores:
  1. Evolução do projeto de dados do TED 1 ao TED 4;
  2. Análise de Viés Algorítmico, Explicabilidade e Conformidade com a LGPD;
  3. Validação da solução junto ao cliente ou comunidade;
  4. Resultados analíticos e recomendações de negócio obtidos;
  5. Dificuldades técnicas/de dados encontradas e respectivas soluções;
  6. Considerações finais;
  7. Atualização do Histórico de Versões.
- **Forma de Realização:** Em grupo (etapa final do projeto).
- **Método de Avaliação:** Avaliação da Versão Final do Documento Técnico, Repositório Git, Pitch Oral e Validação do Parceiro. A nota considerará o impacto do produto de dados para a organização (30%), a qualidade do Data Storytelling e do Pitch (30%), a profundidade da análise ética/LGPD (20%) e o comprovante de entrega assinado (20%).
- **Data de Entrega:** 01/12/2026
- **Valor:** 1,5 pontos.

PLANO DE AVALIAÇÃO

A avaliação considerará o envolvimento dos estudantes nas aulas, nas atividades, a participação em projetos e práticas e a aplicação de instrumentos de avaliação. Neste processo devem-se considerar os aspectos qualitativos e quantitativos.
O plano de avaliação encontra-se descrito abaixo.

#	Instrumento	Dt. Realização ou Entrega	Tipo de Aplicação	Peso	Nível de Uso de Inteligência Artificial
0	Questionário Diagnóstico	04/08/2026	Questionário	0	Diagnóstico (Ponto de partida)
1	TED 01: Etapa 1 - Prospecção, Diagnóstico e Coleta de Dados no Parceiro (TED Extensão)	12/09/2026	TED 5H	1,5	RESTRITO
2	Pesquisa Teórico-Tecnológica (Tecnologias de Big Data e NoSQL)	15/09/2026	Extra Sala	1,0	PERMITIDO COM RESTRIÇÕES
3	TED 02: Etapa 2 - Limpeza, Saneamento e Análise Exploratória (TED Acadêmico)	22/09/2026	TED 5H	1,5	RESTRITO
4	Avaliação Individual Bimestral	06/10/2026	Prova escrita	6,0	PROIBIDO
Total do 1º Bimestre				**10,0**	**Total do Bimestre**
5	TED 03: Etapa 3 - Modelagem Preditiva e Machine Learning (TED Acadêmico)	03/11/2026	TED 5H	1,5	RESTRITO
6	Avaliação Integrada	18/11/2026	Prova escrita	2,0	PROIBIDO
7	Resolução de Problemas 2	24/11/2026	Extra Sala	1,0	PERMITIDO COM RESTRIÇÕES
8	TED 04: Etapa 4 - Análise Ética/LGPD, Data Storytelling e Entrega da Solução Final (TED Extensão)	01/12/2026	TED 5H	1,5	RESTRITO
9	Avaliação Individual Bimestral	08/12/2026	Prova escrita	4,0	PROBIDO
Total do 2º Bimestre				**10,0**	**Total do Bimestre**
Média Final = (BIM1+BIM2) / 2				**10,0**	**Total Semestre**

O plano de avaliação contempla uma proposta sistemática e contínua de avaliação, compreendendo em tempo real o comportamento da turma acerca do aprendizado nas aulas. Este Plano de avaliação será apresentado para a turma no primeiro dia de aula. Serão coletadas sugestões dos estudantes. Desta forma, ajustes poderão ser realizados conforme diálogo e acertos com a turma.

- **Atividade 0. Questionário Diagnóstico:** Será aplicado, no primeiro dia de aula, um questionário diagnóstico contendo questões relacionadas aos indicadores de desempenho do estudante, perfil de leitura, informações gerais e percepções iniciais acerca da avaliação. O questionário será utilizado para se ter uma ideia do ponto de partida de cada estudante e para analisar sua evolução na disciplina.
- **Atividade 1. TED 01: Etapa 1 - Prospecção, Diagnóstico e Coleta de Dados no Parceiro (TED Extensão):** Primeira etapa do Projeto Integrador. O grupo deverá contatar uma empresa pública, privada ou ONG parceira, realizar a entrevista de diagnóstico para mapear os gargalos de informação e coletar o conjunto de dados brutos que alimentará todas as etapas do semestre.
    - **Uso de IA e Evidências:** Uso **RESTRITO**. Permite-se o uso de IA apenas para auxílio na estruturação de formulários de entrevista ou ata de reuniões. Como evidências de autoria, os grupos entregarão o Relatório de Diagnóstico Extensionista, o Termo de Parceria assinado pela organização e a inspeção inicial da base de dados em notebook.
- **Atividade 2. Pesquisa Teórico-Tecnológica (Tecnologias de Big Data e NoSQL):** Realização de uma pesquisa em duplas orientada sobre as principais tecnologias do ecossistema de Big Data abordadas no 1º bimestre (Hadoop HDFS, MapReduce, Apache Spark e Bancos de Dados NoSQL). Os estudantes produzirão um Resumo Técnico (de 1 a 2 páginas) comparando os cenários de aplicação, vantagens, limitações e critérios de escolha de cada arquitetura de armazenamento e processamento para grandes volumes de dados.
    - **Uso de IA e Evidências:** O uso de IA Generativa é **PERMITIDO COM RESTRIÇÕES**, atuando como suporte para organização de ideias e revisão textual. É proibida a geração automatizada e integral do resumo. Como evidências de autoria, o estudante deverá enviar o histórico de prompts utilizado (chat log) anexado ao trabalho e responder a arguições orais rápidas por amostragem em sala de aula.
- **Atividade 3. TED 02: Etapa 2 - Limpeza, Saneamento e Análise Exploratória (TED Acadêmico):** Segunda etapa do Projeto Integrador. Utilizando a mesma base coletada na Etapa 1, o grupo realizará a limpeza técnica dos dados (tratamento de nulos, inconsistências e outliers)

e a Análise Exploratória de Dados (EDA) com gráficos estatísticos para extrair os primeiros insights para o parceiro.

  - **Uso de IA e Evidências:** Uso **RESTRITO**. A IA pode ser consultada para suporte na sintaxe de rotinas do Pandas e Matplotlib. Como evidências de autoria, exige-se o notebook funcional e o Anexo de Transparência de IA detalhando os prompts utilizados e as intervenções manuais realizadas pelo grupo.

- **Atividade 4. Prova Oficial 1º Bimestre (AV6):** Prova individual presencial, contendo 15 questões objetivas e uma discursiva, abrangendo os conceitos de Big Data, ecossistema Hadoop/Spark, bancos NoSQL e manipulação prática de dados com Pandas.
  - **Uso de IA:** O uso de IA nesta atividade é **PROIBIDO**.
- **Atividade 5. TED 03: Etapa 3 - Modelagem Preditiva e Machine Learning (TED Acadêmico):** Terceira etapa do Projeto Integrador. Aplicação de algoritmos de Machine Learning (Scikit-learn) sobre a base limpa da organização parceira para resolver a dor de negócio mapeada na Etapa 1, realizando o treinamento, teste e validação de métricas de performance.
  - **Uso de IA e Evidências:** Uso **RESTRITO**. A IA pode ser consultada para apoio na documentação técnica das bibliotecas. As evidências exigidas são o código-fonte executável, as métricas de validação do modelo e o log de prompts anexado.
- **Atividade 6. Avaliação Integrada (AVI):** Avaliação institucional integrada, composta por conteúdos multidisciplinares do curso, das disciplinas cursadas até o momento, respondida de forma individual.
  - **Uso de IA:** O uso de IA nesta atividade é **PROIBIDO**.
- **Atividade 7. Resolução de Problemas 2 (BeeCrowd - Machine Learning e Estatística):** Resolução de exercícios práticos no BeeCrowd focados em cálculos estatísticos básicos, algoritmos de ordenação e conceitos matemáticos aplicados ao treinamento de modelos.
  - **Uso de IA e Evidências: PERMITIDO COM RESTRIÇÕES**. Envio obrigatório do histórico do chat de IA consultado e validação do código via amostragem oral do docente.
- **Atividade 8. TED 04: Etapa 4 - Análise Ética/LGPD, Data Storytelling e Entrega da Solução Final (TED Extensão):** Etapa conclusiva do Projeto Integrador. O grupo realizará a auditoria de viés e conformidade com a LGPD, construirá uma apresentação em formato de Data Storytelling e entregará formalmente o produto de dados final (dashboard, relatório executivo ou pipeline) para a instituição parceira.
  - **Uso de IA e Evidências:** Uso **RESTRITO**. Evidências de autoria: Entrega do produto de dados funcional, documento de conformidade ética/LGPD, Comprovante de Entrega e Recebimento assinado pelo parceiro e apresentação oral executiva perante a turma.
- **Atividade 9. Avaliação Oficial 2º Bimestre (AV2):** Prova individual presencial, contendo 15 questões objetivas e uma discursiva, abrangendo Análise Exploratória, Visualização de Dados, Machine Learning, Pipelines, LGPD e Ética em Dados.
  - **Uso de IA:** O uso de IA nesta atividade é **PROIBIDO**.
- **Substitutiva:** O aluno que não atingir a média para aprovação terá direito à realização de avaliação substitutiva. A Avaliação Substitutiva terá peso dez (10,0) e substituirá todas as notas do bimestre escolhido pelo discente. A prova contemplará o conteúdo acumulado do semestre e será individual. O uso de IA nesta atividade é **PROIBIDO**.

CLÁUSULA DE USO DE IA

1. Diretrizes Gerais e Fundamentação Ética

A disciplina de **Big Data e Ciência de Dados** está imersa em um ecossistema tecnológico onde a Inteligência Artificial Generativa (IAG) é amplamente utilizada no mercado para otimização de pipelines, escrita de consultas SQL e documentação de código. No entanto, o objetivo fundamental desta disciplina é garantir que o estudante desenvolva raciocínio analítico crítico, compreenda a matemática por trás dos algoritmos de *Machine Learning* e domine as estruturas de manipulação de dados. Por isso, a IAG deve atuar apenas como ferramenta de apoio à produtividade (auxílio sintático ou esclarecimento de erros), não podendo terceirizar a lógica da Análise Exploratória de Dados (EDA) ou as decisões de modelagem estatística.

O nível de permissão para uso de IAG varia conforme a atividade, sendo crucial em projetos de extensão — que envolvem dados de parceiros reais — garantir a governança e a segurança das informações. Sob nenhuma hipótese dados sensíveis, sigilosos ou protegidos pela Lei Geral de Proteção de Dados (LGPD) devem ser inseridos em prompts de IAs públicas. A omissão de uso da IAG, a ausência de declaração formal ou o descumprimento dos limites estabelecidos caracterizam quebra de integridade acadêmica e plágio tecnológico.

Em consonância com o Marco Regulatório da Educação Superior e as diretrizes de integridade científica da Portaria CNPq nº 2.664/2026, os estudantes mantêm autoria e responsabilidade exclusivas e intransferíveis sobre os *dashboards*, códigos, modelos preditivos e relatórios entregues. Erros de processamento, alucinações matemáticas da IA ou vieses algorítmicos presentes nas entregas não serão justificados pelo uso da ferramenta e refletirão diretamente na avaliação de desempenho do grupo.

2. Consequências em Caso de Inobservância e Verificação de Autoria

- **Aferição de Autoria e Defesa Oral:** Havendo divergência entre os anexos de transparência, a complexidade do *pipeline* entregue e a capacidade do estudante de explicá-lo, ou na suspeita de geração integral de código de dados sem revisão, o(s) aluno(s) serão convocados para uma **arguição oral individual ou demonstração de código, de forma presencial**.
- **Sanções Acadêmicas:** A não comprovação do domínio analítico na arguição, o uso não declarado de IAG, o vazamento de dados do parceiro de extensão para plataformas de IA públicas, ou o uso de IA em avaliações **PROIBIDAS**, resultarão na **anulação total e imediata da avaliação**. O caso será passível de notificação por quebra de governança e encaminhado ao Colegiado do Curso para as sanções disciplinares cabíveis.

BIBLIOGRAFIA BÁSICA

1. GOMES, Elisabeth, e Fabiane Braga. **Inteligência Competitiva Tempos Big Data** [Livro eletrônico]. Editora Alta Books, 2017.
2. CARVALHO, André C. P. L. F., D. et al. **Ciência de Dados - Fundamentos e Aplicações** [Livro eletrônico]. Grupo GEN, 2024.
3. BARRY, PAUL. **Use a Cabeça! Python** [Livro eletrônico]. São Paulo: Editora Alta Books, 2018.
4. BEHRMAN, Kennedy R. **Fundamentos de Python para ciência de dados** [Livro eletrônico]. Grupo A, 2023.
5. OLIVEIRA, D. P. R. **Sistemas de Informações Gerenciais - Estratégicas Táticas Operacionais.** 12a Ed. São Paulo: Atlas, 2010.
6. STEPHENS-DAVIDOWITZ, Seth. **Todo Mundo Mente: Big Data, Novos Dados e o que a Internet Nos Diz sobre Quem Realmente Somos** [Livro eletrônico]. Editora Alta Books, 2018.

Periódico:

- **Revista IEEE Transactions on Big Data, link de acesso.** Disponível em: https://ieeexplore.ieee.org/xpl/RecentIssue.jsp?punumber=6687317

BIBLIOGRAFIA COMPLEMENTAR

1. LACERDA, Paulo S. Pádua, D. et al. **Programação em Big Data com R** [Livro eletrônico]. Grupo A, 2021.
2. OLSEN, Wendy. **Coleta de dados** [Livro eletrônico]. Grupo A, 2015.
3. BEIGHLEY, L. **Use a cabeça SQL**. São Paulo: Alta Books, 2008.
4. FÁVERO, Luiz P. **Análise de Dados** [Livro eletrônico]. Grupo GEN, 2015.
5. ALVES, William P. **Programação Python: aprenda de forma rápida** [Livro eletrônico]. Editora Saraiva, 2021.

Periódico:

- **Revista Iberoamericana de Inteligência Artificial, link de acesso.** Disponível em: https://journal.iberamia.org/index.php/intartif/index

BIBLIOGRAFIA DE APOIO/APROFUNDAMENTO

Será disponibilizada no decorrer das unidades temáticas, no Ambiente Virtual de Aprendizagem (UB Virtual).

Balsas, 30 de julho de 2026

gov.br Documento assinado digitalmente
ALEX ROGALESKI MARQUES
Data: 02/08/2026 18:19:37-0300
Verifique em https://validar.iti.gov.br

Alex Rogaleski Marques
Professor da Unidade Curricular

gov.br Documento assinado digitalmente
JAKSON FERREIRA DE SOUSA
Data: 03/08/2026 17:03:58-0300
Verifique em https://validar.iti.gov.br

Jakson Ferreira de Sousa
Coordenador do Curso

CAMILA SOUSA DA SILVA:02221027302 Assinado de forma digital por CAMILA SOUSA DA SILVA:02221027302 Dados: 2026.08.03 19:32:35 -03'00'

Camila Sousa da Silva
Direção Acadêmica

PLANO DE AULA

ANEXO 01

	Plano de Aula - Trilha de Aprendizagem (Quarta- feira)			
Nº da Aula	**Data**	**Conteúdo Programático a ser trabalhado**	**Tipo da Aula**	**Observação**
1	04/08	Apresentação da Disciplina, Plano de Ensino, Critérios de Avaliação e Política de Uso de IA. Atividade 0: Questionário Diagnóstico. Unidade 1: Conceitos Fundamentais de Big Data (Os 5 Vs) e Ciência de Dados.	Teórica/Prática	3 horas
2	11/08	Unidade 1: O Ciclo de Vida de um Projeto de Ciência de Dados e a diferença entre BI, Análise de Dados e Big Data. Apresentação e Detalhamento da Metodologia Extensionista e do Projeto Integrador (TEDs 1 a 4).	Teórica/Prática	3 horas
3	15/08	TED 01 (Início - 5h): Orientação e Execução da Etapa 1 - Prospecção, Diagnóstico e Coleta de Dados na Organização Parceira (TED Extensão).	TED	5 horas (sábado)
4	18/08	Unidade 2: Arquiteturas de Referência de Big Data (Lambda e Kappa). O Ecossistema Hadoop: HDFS, YARN e o modelo MapReduce.	Teórica/Prática	3 horas
5	25/08	Unidade 4: Ferramentas e Linguagens. Python para Ciência de Dados (Jupyter/Google Colab) e Computação Numérica com a biblioteca NumPy.	Teórica/Prática	3 horas
6	01/09	Unidade 4: Manipulação de Dados com Pandas. Leitura de dados, criação de DataFrames, seleção, filtragem e estatísticas descritivas.	Teórica/Prática	3 horas
7	08/09	Unidade 5: Coleta, Limpeza e Pré-processamento de Dados (Data Wrangling). Tratamento de valores ausentes, remoção de duplicidades e conversão de tipos com Pandas. Lançamento da lista Resolução de Problemas 1.	Teórica/Prática	3 horas
8	12/09	TED 02 (Início - 5h): Orientação e Desenvolvimento da Etapa 2 - Limpeza, Saneamento e Análise Exploratória na Base do Parceiro (TED Acadêmico). Entrega do TED 01.	TED	5 horas (sábado)
9	15/09	Unidade 2: Processamento de Grandes Volumes de Dados em Memória com Apache Spark. Conceito de RDDs, DataFrames no Spark e PySpark. Entrega da Pesquisa Teórico-Tecnológica.	Teórica/Prática	3 horas
10	22/09	Unidade 3: Armazenamento de Dados em Larga Escala (NoSQL). Limitações do SQL e Categorias NoSQL (Documento, Chave-Valor, Colunar, Grafo). Entrega do TED 02.	Teórica/Prática	3 horas
11	26/09	Laboratório Prático de NoSQL: Hands-on de Manipulação de Dados Não Relacionais — Exercícios Práticos de Consultas em Documentos (MongoDB) e Estruturas Chave-Valor.	Prática	3 horas (sábado)
12	29/09	Unidade 5: Análise Exploratória de Dados (EDA) e Visualização de Dados com as bibliotecas Matplotlib e Seaborn. Laboratório prático preparatório para a avaliação.	Teórica/Prática	3 horas
13	06/10	AV6 - Avaliação Oficial.	Avaliação - 1º Bimestre	3 horas
14	17/10	TED 03 (Início - 5h): Orientação e Desenvolvimento da Etapa 3 - Modelagem Preditiva e Machine Learning sobre os Dados do Parceiro (TED Acadêmico).	TED	5 horas (sábado)
15	20/10	Unidade 6: Introdução ao Machine Learning. Conceitos de Aprendizagem Supervisionada e Não Supervisionada. Algoritmos de Regressão Linear e Múltipla.	Teórica/Prática	3 horas
16	27/10	Unidade 6: Algoritmos de Classificação (Árvores de Decisão, K-NN) e Métricas de Avaliação (Acurácia, Precisão, Recall, Matriz de Confusão). Lançamento da lista Resolução de Problemas 2 (BeeCrowd).	Teórica/Prática	3 horas
17	03/11	Unidade 6: Aprendizagem Não Supervisionada e Algoritmos de Clusterização (K-Means). Segmentação de dados e identificação de agrupamentos. Entrega do TED 03.	Teórica/Prática	3 horas
18	10/11	Unidade 7: Engenharia de Dados e Pipelines de Dados (ETL/ELT). Conceitos de automação e orquestração de processos com Apache Airflow.	Teórica/Prática	3 horas
19	14/11	TED 04 (Início - 5h): Orientação e Finalização da Etapa 4 - Análise Ética/LGPD, Data Storytelling e Validação do	TED	5 horas (sábado)

		Comprovante de Entrega (TED Extensão).		
20	17/11	Técnicas de Comunicação Analítica e Data Storytelling: Como estruturar relatórios executivos e apresentações de impacto para tomadores de decisão. Laboratório de Suporte Técnico para o Projeto.	Teórica/Prática	3 horas
21	24/11	Unidade 7: Ética, Transparência e Privacidade em Ciência de Dados. Viés Algorítmico, Explicabilidade (XAI) e o impacto da LGPD nos projetos de dados. Entrega da Lista de Exercícios 2.	Teórica/Prática	3 horas
22	01/12	Apresentação dos Projetos Integradores Extensionistas (TED 04) e Validação dos Comprovantes de Entrega com as Organizações Parceiras.	Teórica/Prática	3 horas
23	08/12	AV4 - Avaliação Oficial.	Avaliação - 2º Bimestre	3 horas
24	15/12	AV10 - Avaliação Substitutiva.	Avaliação Substitutiva	3 horas

As datas e os respectivos conteúdos programáticos, referentes a aulas teóricas, práticas e atividades extraclasse, poderão ser alterados conforme necessidades acadêmicas ou institucionais, sendo tais alterações previamente comunicadas aos discentes.

ANEXO 02

PLANO DE COMPENSAÇÃO DE AUSÊNCIA

1. DISCIPLINA: Big Data e Ciências de Dados	**2. PERÍODO LETIVO:** 2026.2
3. PROFESSOR: Alex Rogaleski Marques	
4. CURSO: Análise e Desenvolvimento de Sistemas e Sistemas de Informação	
5. ANO/MÓDULO: 2° ano ADS e 4º ano SI / módulo azul	**6. CARGA HORÁRIA:** 80h

MÊS	
Agosto	**Atividade**: Leitura de artigo científico ou capítulo indicado sobre os conceitos fundamentais de Big Data, os 5 Vs e o papel do cientista e engenheiro de dados nas organizações modernas. O aluno deverá produzir uma Resenha Crítica (mínimo de 2 laudas) correlacionando as arquiteturas de dados com os desafios de negócios atuais. **Componente Oral**: Arguição Técnica Individual (5 minutos), na qual o estudante apresentará oralmente a análise do artigo e responderá a perguntas do docente sobre os impactos do Big Data na tomada de decisão gerencial. **Uso de IA e Evidências de Autoria:** Uso RESTRITO. A IA pode ser utilizada unicamente como suporte de leitura para síntese de conceitos. Como evidência de autoria, o estudante deverá entregar em anexo o histórico de prompts consultados (chat log) e realizar a defesa oral obrigatória na arguição técnica individual perante o docente. **Bibliografia**: • GOMES, Elisabeth, e Fabiane Braga. Inteligência Competitiva Tempos Big Data. Livro eletrônico. Editora Alta Books, 2017. • STEPHENS-DAVIDOWITZ, Seth. Todo Mundo Mente: Big Data, Novos Dados e o que a Internet Nos Diz sobre Quem Realmente Somos. Livro eletrônico. Editora Alta Books, 2018. • Periódico: Revista IEEE Transactions on Big Data. Link de acesso: https://ieeexplore.ieee.org/xpl/RecentIssue.jsp?punumber=6687317
Setembro	**Atividade**: Elaboração de um Relatório Técnico detalhando as diferenças entre bancos de dados relacionais (SQL) e não relacionais (NoSQL). O documento deve conter a análise comparativa entre os modelos de NoSQL (Documento, Chave-Valor, Colunar e Grafo), apresentando diagramas de estrutura de dados para cada categoria e justificando cenários práticos de aplicação de cada um. **Componente Oral**: Apresentação em Lousa/Quadro (5 a 7 minutos), na qual o estudante desenhará a estrutura de dados de

	uma categoria NoSQL sorteada na hora pelo professor e explicará a diferença de escalabilidade frente ao modelo relacional. **Uso de IA e Evidências de Autoria**: Uso **RESTRITO**. A IA pode ser utilizada como ferramenta de apoio para consulta de sintaxe ou esclarecimento de dúvidas conceituais. Como evidência de autoria, é obrigatória a apresentação em lousa com resolução ao vivo do problema proposto pelo professor, acompanhada da entrega do log de prompts da IA. **Bibliografia**: • CARVALHO, André C. P. L. F., D. et al. Ciência de Dados - Fundamentos e Aplicações. Livro eletrônico. Grupo GEN, 2024. • OLIVEIRA, D. P. R. Sistemas de Informações Gerenciais - Estratégicas Táticas Operacionais. 12a Ed. São Paulo: Atlas, 2010. • Periódico: Revista Iberoamericana de Inteligência Artificial. Link de acesso: https://journal.iberamia.org/index.php/intartif/index
Outubro	**Atividade**: Desenvolvimento de um Notebook no Google Colab abordando técnicas de Coleta, Limpeza (Data Wrangling) e Análise Exploratória de Dados (EDA) com as bibliotecas Pandas, Matplotlib e Seaborn. O notebook deve conter a resolução de problemas de dados ausentes, remoção de outliers e a criação de pelo menos 4 gráficos inter-relacionados acompanhados de explicações formatadas em texto. **Componente Oral**: Defesa Prática de Código no Laboratório (5 minutos), na qual o estudante abrirá seu notebook perante o professor, executará os blocos de código e demonstrará a geração de um novo gráfico descritivo solicitada na hora. **Uso de IA e Evidências de Autoria**: Uso **RESTRITO**. O aluno pode consultar a IA para auxílio no tratamento de erros de código. As evidências de autoria serão compostas pela modificação e execução do algoritmo em tempo real no laboratório solicitada pelo professor, além do envio do link/registro do histórico do chat utilizado com a IA. **Bibliografia**: • BEHRMAN, Kennedy R. Fundamentos de Python para ciência de dados. Livro eletrônico. Grupo A, 2023. • BARRY, PAUL. Use a Cabeça! Python. Livro eletrônico. São Paulo: Editora Alta Books, 2018. • Periódico: Revista IEEE Transactions on Big Data. Link de acesso: https://ieeexplore.ieee.org/xpl/RecentIssue.jsp?punumber=6687317
Novembro	**Atividade**: Produção e gravação de uma Videoaula Didática de até 7 minutos demonstrando o fluxo completo de construção e avaliação de um Modelo Preditivo de Machine Learning (Classificação ou Regressão) utilizando a biblioteca Scikit-learn. O vídeo

	deve mostrar a gravação de tela com a divisão dos dados em treino/teste, o treinamento do algoritmo e a exibição da matriz de confusão/métricas de acurácia. O vídeo deve ser disponibilizado via link em nuvem ou plataforma de vídeos. **Componente Oral**: Sessão de Perguntas e Respostas / Pitch da Videoaula (5 minutos), em que o estudante exibirá um trecho do vídeo e responderá a perguntas técnicas do docente sobre a escolha do algoritmo e das métricas de avaliação utilizadas. **Uso de IA e Evidências de Autoria**: Uso **RESTRITO**. Permitido o uso de IA para auxílio na estruturação do roteiro da videoaula. As evidências de autoria exigidas são o registro audiovisual do aluno apresentando o conteúdo, o Anexo de Transparência de IA com o histórico dos prompts e a arguição presencial de Q&A com o professor. **Bibliografia**: • CARVALHO, André C. P. L. F., D. et al. Ciência de Dados - Fundamentos e Aplicações. Livro eletrônico. Grupo GEN, 2024. • FÁVERO, Luiz P. Análise de Dados. Livro eletrônico. Grupo GEN, 2015. • Periódico: Revista Iberoamericana de Inteligência Artificial. Link de acesso: https://journal.iberamia.org/index.php/intartif/index
Dezembro	**Atividade**: Elaboração de um Infográfico Técnico ou Mapa Conceitual abrangendo os princípios de Engenharia de Dados, Pipelines ETL/ELT, Arquiteturas de Big Data, Ética em Algoritmos e os impactos da Lei Geral de Proteção de Dados (LGPD). O material deve organizar visualmente o fluxo de um projeto de dados desde a coleta ética até a tomada de decisão gerencial. **Componente Oral**: Defesa do Infográfico (5 a 8 minutos), na qual o estudante apresentará o material impresso ou projetado para o professor, justificando a importância da conformidade legal da LGPD e a mitigação de vieses algorítmicos em projetos corporativos. **Uso de IA e Evidências de Autoria**: Uso **RESTRITO**. A IA pode ser usada para idealização de layouts ou revisão do texto. Como evidência de autoria, exige-se a defesa presencial do infográfico projetado/impresso com resposta a questionamentos técnicos diretos do docente, acompanhada do relatório reflexivo e histórico de prompts anexado. **Bibliografia**: • GOMES, Elisabeth, e Fabiane Braga. Inteligência Competitiva Tempos Big Data. Livro eletrônico. Editora Alta Books, 2017. • STEPHENS-DAVIDOWITZ, Seth. Todo Mundo Mente: Big Data, Novos Dados e o que a Internet Nos Diz sobre Quem Realmente Somos. Livro eletrônico. Editora Alta Books, 2018.

	• Periódico: Revista IEEE Transactions on Big Data. Link de acesso: https://ieeexplore.ieee.org/xpl/RecentIssue.jsp?punumber=6687317